如何利用 urllib 包获取网络资源

发行版本 3.12.4

Guido van Rossum and the Python development team

七月 31, 2024

Python Software Foundation Email: docs@python.org

Contents

1	概述	2
2	获取 URL 资源 2.1 数据	2 3 4
3	异常的处理 3.1 URLError 3.2 HTTPError 3.3 总之	
4	info 和 geturl 方法	8
5	Opener 利 Handler	8
6	基本认证	8
7	代理	9
8	套接字与分层	10
9	备注	10
索	31	11

作者

Michael Foord

1 概述

Related Articles

关于如何用 Python 获取 web 资源,以下文章或许也很有用:

• 基本身份认证

基本认证的教程,带有一些 Python 示例。

urllib.request 是用于获取 URL(统一资源定位符)的 Python 模块。它以 *urlopen* 函数的形式提供了一个非常简单的接口,能用不同的协议获取 URL。同时它还为处理各种常见情形提供了一个稍微复杂一些的接口——比如:基础身份认证、cookies、代理等等。这些功能是由名为 handlers 和 opener 的对象提供的。

urllib.request 支持多种"URL 方案"(通过 URL 中 ": "之前的字符串加以区分——如 "ftp://python.org/"中的 "ftp")即为采用其关联网络协议(FTP、HTTP 之类)的 URL 方案。本教程重点关注最常用的 HTTP 场景。

对于简单场景而言,urlopen 用起来十分容易。但只要在打开 HTTP URL 时遇到错误或非常情况,就需要对超文本传输协议有所了解才行。最全面、最权威的 HTTP 参考是 RFC 2616。那是一份技术文档,并没有追求可读性。本文旨在说明 urllib 的用法,为了便于阅读也附带了足够详细的 HTTP 信息。本文并不是为了替代 urllib.request 文档,只是其补充说明而已。

2 获取 URL 资源

urllib.request 最简单的使用方式如下所示:

```
import urllib.request
with urllib.request.urlopen('http://python.org/') as response:
   html = response.read()
```

如果想通过 URL 获取资源并临时存储一下,可以采用 shutil.copyfileobj() 和 tempfile.NamedTemporaryFile()函数:

```
import shutil
import tempfile
import urllib.request

with urllib.request.urlopen('http://python.org/') as response:
    with tempfile.NamedTemporaryFile(delete=False) as tmp_file:
        shutil.copyfileobj(response, tmp_file)

with open(tmp_file.name) as html:
    pass
```

urllib 的很多用法就是这么简单(注意 URL 不仅可以 http: 开头,还可以是 ftp:、file:等)。不过本教程的目的是介绍更加复杂的应用场景,重点还是关注 HTTP。

HTTP 以请求和响应为基础——客户端生成请求,服务器发送响应。urllib.request 用 Request 对象来表示要生成的 HTTP 请求。最简单的形式就是创建一个 Request 对象,指定了想要获取的 URL。用这个 Request 对象作为参数调用 urlopen,将会返回该 URL 的响应对象。响应对象类似于文件对象,就是说可以对其调用 .read() 之类的命令:

```
import urllib.request
req = urllib.request.Request('http://python.org/')
with urllib.request.urlopen(req) as response:
   the_page = response.read()
```

请注意, urllib.request 用同一个 Request 接口处理所有 URL 方案。比如可生成 FTP 请求如下:

```
req = urllib.request.Request('ftp://example.com/')
```

就 HTTP 而言,Request 对象能够做两件额外的事情: 首先可以把数据传给服务器。其次,可以将 有关数据或请求本身的额外信息(metadata)传给服务器——这些信息将会作为 HTTP "头部"数据发送。下面依次看下。

2.1 数据

有时需要向某个 URL 发送数据,通常此 URL 会指向某个 CGI(通用网关接口)脚本或其他 web 应用。对于 HTTP 而言,这通常会用所谓的 POST 请求来完成。当要把 Web 页填写的 HTML 表单提交时,浏览器通常会执行此操作。但并不是所有的 POST 都来自表单:可以用 POST 方式传输任何数据到自己的应用上。对于通常的 HTML 表单,数据需要以标准的方式编码,然后作为 data 参数传给 Request 对象。编码过程是用urllib.parse 库的函数完成的:

请注意,有时还需要采用其他编码,比如由 HTML 表单上传文件——更多细节请参见 HTML 规范,提交表单。

如果不传递 data 参数, urllib 将采用 **GET** 请求。**GET** 和 **POST** 请求有一点不同,**POST** 请求往往具有"副作用",他们会以某种方式改变系统的状态。例如,从网站下一个订单,购买一大堆罐装垃圾并运送到家。尽管 HTTP 标准明确指出 POST 总是要导致副作用,而 GET 请求 从来不会导致副作用。但没有什么办法能阻止 GET 和 POST 请求的副作用。数据也可以在 HTTP GET 请求中传递,只要把数据编码到 URL 中即可。

做法如下所示:

```
>>> import urllib.request
>>> import urllib.parse
>>> data = {}
>>> data['name'] = 'Somebody Here'
>>> data['location'] = 'Northampton'
>>> data['language'] = 'Python'
>>> url_values = urllib.parse.urlencode(data)
>>> print(url_values) # The order may differ from below.
name=Somebody+Here&language=Python&location=Northampton
>>> url = 'http://www.example.com/example.cgi'
```

(续下页)

```
>>> full_url = url + '?' + url_values
>>> data = urllib.request.urlopen(full_url)
```

请注意,完整的 URL 是通过在其中添加?创建的,后面跟着经过编码的数据。

2.2 HTTP 头部信息

下面介绍一个具体的 HTTP 头部信息,以此说明如何在 HTTP 请求加入头部信息。

有些网站¹ 不愿被程序浏览到,或者要向不同的浏览器发送不同版本² 的网页。默认情况下,urllib 将自身标识为 "Python-urllib/xy" (其中 × 、y 是 Python 版本的主、次版本号,例如 Python-urllib/2.5),这可能会让网站不知所措,或者干脆就使其无法正常工作。浏览器是通过头部信息 User-Agent³ 来标识自己的。在创建 Request 对象时,可以传入字典形式的头部信息。以下示例将生成与之前相同的请求,只是将自身标识为某个版本的 Internet Explorer⁴:

响应对象也有两个很有用的方法。请参阅有关info 和 geturl 部分,了解出现问题时会发生什么。

3 异常的处理

当 urlopen 无法处理响应信息时将会引发 URLError (当然与 Python API 通常的情况一样,也可能会引发如 ValueError, TypeError 之类的内置异常)。

HTTPError 是在 HTTP URL 的特定情况下引发的 URLError 的子类。

上述异常类是从 urllib.error 模块中导出的。

¹ 例如 Google。

² 对于网站设计而言,探测不同的浏览器是非常糟糕的做法——更为明智的做法是采用 web 标准构建网站。不幸的是,很多网站依然向不同的浏览器发送不同版本的网页。

³ MSIE 6 的 user-agent 信息是 "Mozilla/4.0 (compatible; MSIE 6.0; Windows NT 5.1; SV1; .NET CLR 1.1.4322)"

⁴ 有关 HTTP 请求的头部信息,详情请参阅 Quick Reference to HTTP Headers。

3.1 URLError

触发 URLError 的原因,通常是网络不通(或者没有到指定服务器的路由),或者指定的服务器不存在。这时触发的异常会带有一个 reason 属性,是一个包含错误代码和文本错误信息的元组。

例如:

```
>>> req = urllib.request.Request('http://www.pretend_server.org')
>>> try: urllib.request.urlopen(req)
... except urllib.error.URLError as e:
... print(e.reason)
...
(4, 'getaddrinfo failed')
```

3.2 HTTPError

来自服务器的每个 HTTP 响应都包含一个数字形式的"状态码"。有时该状态码表明服务器无法完成请求。默认的处理器将会为你处理其中的部分响应(例如,当响应为要求客户端从另一 URL 获取文档的"重定向"响应时,urllib 将为你处理该响应)。对于无法处理的响应,urlopen 将会引发 HTTPError。典型的错误包括"404"(页面未找到)、"403"(请求遭拒)和"401"(需要身份认证)等。

全部的 HTTP 错误码请参阅 RFC 2616。

被引发的 HTTPError 实例将有一个整数形式的'code' 属性,对应于服务器发送的错误信息。

错误代码

由于默认处理函数会自行处理重定向(300以内的错误码),而且100--299的状态码表示成功,因此通常只会出现400--599的错误码。

http.server.BaseHTTPRequestHandler.responses 是很有用的响应码字典,其中给出了RFC 2616 用到的所有响应代码。为方便起见,将此字典转载如下:

```
# Table mapping response codes to messages; entries have the
# form {code: (shortmessage, longmessage)}.
responses = {
   100: ('Continue', 'Request received, please continue'),
   101: ('Switching Protocols',
          'Switching to new protocol; obey Upgrade header'),
   200: ('OK', 'Request fulfilled, document follows'),
   201: ('Created', 'Document created, URL follows'),
   202: ('Accepted',
          'Request accepted, processing continues off-line'),
   203: ('Non-Authoritative Information', 'Request fulfilled from cache'),
   204: ('No Content', 'Request fulfilled, nothing follows'),
   205: ('Reset Content', 'Clear input form for further input.'),
   206: ('Partial Content', 'Partial content follows.'),
   300: ('Multiple Choices',
          'Object has several resources -- see URI list'),
   301: ('Moved Permanently', 'Object moved permanently -- see URI list'),
   302: ('Found', 'Object moved temporarily -- see URI list'),
    303: ('See Other', 'Object moved -- see Method and URL list'),
   304: ('Not Modified',
```

(续下页)

(接上页)

```
'Document has not changed since given time'),
305: ('Use Proxy',
      'You must use proxy specified in Location to access this '
      'resource.'),
307: ('Temporary Redirect',
      'Object moved temporarily -- see URI list'),
400: ('Bad Request',
      'Bad request syntax or unsupported method'),
401: ('Unauthorized',
      'No permission -- see authorization schemes'),
402: ('Payment Required',
      'No payment -- see charging schemes'),
403: ('Forbidden',
      'Request forbidden -- authorization will not help'),
404: ('Not Found', 'Nothing matches the given URI'),
405: ('Method Not Allowed',
      'Specified method is invalid for this server.'),
406: ('Not Acceptable', 'URI not available in preferred format.'),
407: ('Proxy Authentication Required', 'You must authenticate with '
      'this proxy before proceeding.'),
408: ('Request Timeout', 'Request timed out; try again later.'),
409: ('Conflict', 'Request conflict.'),
410: ('Gone',
      'URI no longer exists and has been permanently removed.'),
411: ('Length Required', 'Client must specify Content-Length.'),
412: ('Precondition Failed', 'Precondition in headers is false.'),
413: ('Request Entity Too Large', 'Entity is too large.'),
414: ('Request-URI Too Long', 'URI is too long.'),
415: ('Unsupported Media Type', 'Entity body in unsupported format.'),
416: ('Requested Range Not Satisfiable',
      'Cannot satisfy request range.'),
417: ('Expectation Failed',
      'Expect condition could not be satisfied.'),
500: ('Internal Server Error', 'Server got itself in trouble'),
501: ('Not Implemented',
      'Server does not support this operation'),
502: ('Bad Gateway', 'Invalid responses from another server/proxy.'),
503: ('Service Unavailable',
      'The server cannot process the request due to a high load'),
504: ('Gateway Timeout',
      'The gateway server did not receive a timely response'),
505: ('HTTP Version Not Supported', 'Cannot fulfill request.'),
```

当错误被引发时服务器会通过返回 HTTP 错误码 和错误页面进行响应。你可以在返回的页面上使用 HTTPError 实例作为响应。这意味着除了 code 属性之外,它还像 urllib.response 模块: 所返回对象那样具有 read, geturl 和 info 等方法:

(续下页)

3.3 总之

因此当你想为 HTTPError 或 URLError 做好准备时有两种基本的方案。我更倾向使用第二种方案。

第一种方案

```
from urllib.request import Request, urlopen
from urllib.error import URLError, HTTPError
req = Request(someurl)
try:
    response = urlopen(req)
except HTTPError as e:
    print('The server couldn\'t fulfill the request.')
    print('Error code: ', e.code)
except URLError as e:
    print('We failed to reach a server.')
    print('Reason: ', e.reason)
else:
    # everything is fine
```

备注

except HTTPError 必须首先被处理, 否则 except URLError 将会 同时捕获 HTTPError。

第二种方案

```
from urllib.request import Request, urlopen
from urllib.error import URLError
req = Request(someurl)
try:
    response = urlopen(req)
except URLError as e:
    if hasattr(e, 'reason'):
        print('We failed to reach a server.')
        print('Reason: ', e.reason)
    elif hasattr(e, 'code'):
        print('The server couldn\'t fulfill the request.')
        print('Error code: ', e.code)
else:
    # everything is fine
```

4 info 和 geturl 方法

urlopen 返回的响应(或 HTTPError 实例)包含两个有用的方法 info() 和 geturl() 并且是在 urllib. response 模块中定义的。

- **geturl** ——返回所获取页面的真实 URL。该方法很有用,因为 urlopen(或 **opener** 对象)可能已经经过了一次重定向。已获取页面的 URL 未必就是所请求的 URL。
- **info** 该方法返回一个类似字典的对象,描述了所获取的页面,特别是由服务器送出的头部信息 (headers)。目前它是一个 http.client.HTTPMessage 实例。

典型的标头包括'Content-length', 'Content-type' 等等。请参阅 HTTP 标头快速参考 获取 HTTP 标头的完整列表及其含义和用法的简要说明。

5 Opener 和 Handler

当你获取 URL 时会使用一个 opener (名称可能有些令人困惑的 urllib.request.OpenerDirector 的实例)。通常我们会使用默认的 opener ——通过 urlopen ——但你也可以创建自定义的 opener。opener 还会用到 handler。所有"繁重工作"都是由 handler 来完成的。每种 handler 都知道要以何种 URL 方案 (http, ftp 等等)来打开特定的 URL,或是如何处理 URL 打开时的特定操作,例如 HTTP 重定向或 HTTP cookie 等。

若要用已安装的某个 handler 获取 URL,需要创建一个 opener 对象,例如处理 cookie 的 opener,或对重定向不做处理的 opener。

若要创建 opener, 请实例化一个 OpenerDirector , 然后重复调用 add_handler(some_handler_instance)。

或者也可以用 build_opener, 这是个用单次调用创建 opener 对象的便捷函数。build_opener 默认会添加几个 handler, 不过还提供了一种快速添加和/或覆盖默认 handler 的方法。

可能还需要其他类型的 handler, 以便处理代理、身份认证和其他常见但稍微特殊的情况。

install_opener 可用于让 opener 对象成为 (全局) 默认 opener。这意味着调用 urlopen 时会采用已安装的 opener。

opener 对象带有一个`open 方法,可供直接调用以获取 url,方式与 urlopen 函数相同。除非是为了调用方便,否则没必要去调用 install_opener。

6 基本认证

为了说明 handler 的创建和安装过程我们将使用 HTTPBasicAuthHandler。有关该主题的更详细讨论 -- 包括对基本身份认证的原理的阐述 -- 请参阅 Basic Authentication Tutorial。

如果需要身份认证,服务器会发送一条请求身份认证的头部信息(以及 401 错误代码)。这条信息中指明了身份认证方式和"安全区域(realm)"。格式如下所示: WWW-Authenticate: SCHEME realm="REALM"。例如

WWW-Authenticate: Basic realm="cPanel Users"

然后,客户端应重试发起请求,请求数据中的头部信息应包含安全区域对应的用户名和密码。这就是"基本身份认证"。为了简化此过程,可以创建 HTTPBasicAuthHandler 的一个实例及使用它的 opener。

HTTPBasicAuthHandler 用一个名为密码管理器的对象来管理 URL、安全区域与密码、用户名之间的映射关系。如果知道确切的安全区域(来自服务器发送的身份认证头部信息),那就可以用到 HTTPPasswordMgr。通常人们并不关心安全区域是什么,这时用 HTTPPasswordMgrWithDefaultRealm 就很方便,允许

为 URL 指定默认的用户名和密码。当没有为某个安全区域提供用户名和密码时,就会用到默认值。下面用 None 作为 add_password 方法的安全区域参数,表明采用默认用户名和密码。

首先需要身份认证的是顶级 URL。比传给.add_password() 的 URL 级别"更深"的 URL 也会得以匹配:

```
# create a password manager
password_mgr = urllib.request.HTTPPasswordMgrWithDefaultRealm()

# Add the username and password.
# If we knew the realm, we could use it instead of None.
top_level_url = "http://example.com/foo/"
password_mgr.add_password(None, top_level_url, username, password)

handler = urllib.request.HTTPBasicAuthHandler(password_mgr)

# create "opener" (OpenerDirector instance)
opener = urllib.request.build_opener(handler)

# use the opener to fetch a URL
opener.open(a_url)

# Install the opener.
# Now all calls to urllib.request.urlopen use our opener.
urllib.request.install_opener(opener)
```

备注

在上面的救命中我们只向 build_opener 提供了 HTTPBasicAuthHandler。在默认情况下 opener 会包含针对常见状况的处理器 -- ProxyHandler (如果设置了代理如设置了 http_proxy 环境变量), UnknownHandler, HTTPHandler, HTTPDefaultErrorHandler, HTTPRedirectHandler, FTPHandler, FileHandler, DataHandler, HTTPErrorProcessor。

top_level_url 其实 要么是一条完整的 URL (包括 "http:" 部分和主机名及可选的端口号), 比如 "http://example.com/", 要么是一条"访问权限"(即主机名,及可选的端口号),比如 "example.com"或 "example.com:8080"(后一个示例包含了端口号)。访问权限 不得包含"用户信息"部分——比如 "joe:password@example.com"就不正确。

7 代理

urllib 将自动检测并使用代理设置。这是通过 ProxyHandler 实现的,当检测到代理设置时,是正常 handler 链中的一部分。通常这是一件好事,但有时也可能会无效⁵。一种方案是配置自己的 ProxyHandler ,不要定义代理。设置的步骤与 *Basic Authentication* handler 类似:

```
>>> proxy_support = urllib.request.ProxyHandler({})
>>> opener = urllib.request.build_opener(proxy_support)
>>> urllib.request.install_opener(opener)
```

备注

⁵ 本人必须使用代理才能在工作中访问互联网。如果尝试通过代理获取 *localhost* URL,将会遭到阻止。IE 设置为代理模式,urllib 就会获取到配置信息。为了用 localhost 服务器测试脚本,我必须阻止 urllib 使用代理。

目前 urllib.request 尚不支持通过代理抓取 https 链接地址。但此功能可以通过扩展 urllib.request 来启用,如以下例程所示⁶。

备注

如果设置了 REQUEST_METHOD 变量,则会忽略 HTTP_PROXY;参阅 getproxies() 文档。

8 套接字与分层

Python 获取 Web 资源的能力是分层的。urllib 用到的是 http.client 库,而后者又用到了套接字库。

从 Python 2.3 开始,可以指定套接字等待响应的超时时间。这对必须要读到网页数据的应用程序会很有用。默认情况下,套接字模块 不会超时并且可以挂起。目前,套接字超时机制未暴露给 http.client 或 urllib.request 层使用。不过可以为所有套接字应用设置默认的全局超时。

```
import socket
import urllib.request

# timeout in seconds
timeout = 10
socket.setdefaulttimeout(timeout)

# this call to urllib.request.urlopen now uses the default timeout
# we have set in the socket module
req = urllib.request.Request('http://www.voidspace.org.uk')
response = urllib.request.urlopen(req)
```

9 备注

这篇文档由 John Lee 审订。

⁶ urllib 的 SSL 代理 opener (CONNECT 方法): ASPN Cookbook Recipe。

索引

R

RFC

RFC 2616, 2, 5